

Tarea 3

Roberto Gutiérrez-Sánchez, Jimena Salas-Alfaro
 rogutierrez@estudiantec.cr jimenamaria598@gmail.com
 Instituto Tecnológico de Costa Rica
 Escuela de Ingeniería Electrónica
 Introducción al Reconocimiento de Patrones

I. RELACIONES EMPLEADAS EN LAS DEMOSTRACIONES

Sea s un escalar:

$$\mathbf{A}\mathbf{I} = \mathbf{A} = \mathbf{I}\mathbf{A} \quad (1)$$

$$\text{tr}(s) = s \quad (2)$$

$$\nabla_{\mathbf{A}^T} \text{tr}(\mathbf{A}\mathbf{B}\mathbf{A}^T\mathbf{C}) = \mathbf{B}^T\mathbf{A}^T\mathbf{C}^T + \mathbf{B}\mathbf{A}^T\mathbf{C} \quad (3)$$

Si $\mathbf{A}\mathbf{B}$ es cuadrada

$$\nabla_{\mathbf{A}} \text{tr}(\mathbf{B}\mathbf{A}) = \nabla_{\mathbf{A}} \text{tr}(\mathbf{A}\mathbf{B}) = \mathbf{B}^T \quad (4)$$

$$\nabla_{\mathbf{A}} f(\mathbf{A}) = (\nabla_{\mathbf{A}^T} f(\mathbf{A}))^T \quad (5)$$

II. DEMOSTRACIONES MATEMÁTICAS

II-A. Ejercicio 1.1

Si se sabe que con los vectores $\underline{\mathbf{u}}$ y $\underline{\mathbf{v}}$ del mismo tamaño se cumple que

$$\underline{\mathbf{u}}^T \underline{\mathbf{v}} = \sum_{i=1}^n u_i v_i \quad (6)$$

Se puede convertir la siguiente suma

$$\sum_{i=1}^n w^{(i)} (\underline{\theta}^T \underline{\mathbf{x}}^{(i)} - y^{(i)})^2 = \sum_{i=1}^n u_i w^{(i)} u_i = \underline{\mathbf{u}}^T \underline{\mathbf{v}} \quad (7)$$

Con $u_i = \underline{\theta}^T \underline{\mathbf{x}}^{(i)} - y^{(i)}$ y $v_i = w^{(i)} u_i$

Generalizando para el vector $\underline{\mathbf{u}}$, se tiene que

$$\underline{\mathbf{u}} = \begin{bmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(n)} \end{bmatrix} \underline{\theta} - \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix} = \mathbf{X}\underline{\theta} - \underline{\mathbf{y}} \quad (8)$$

Ahora para el vector $\underline{\mathbf{v}}$, para escalar cada elemento de un vector se debe multiplicar por una matriz diagonal con las escalas

$$\underline{\mathbf{v}} = \begin{bmatrix} w^{(1)}u^{(1)} \\ w^{(2)}u^{(2)} \\ \vdots \\ w^{(n)}u^{(n)} \end{bmatrix} = \begin{bmatrix} w^{(1)} & 0 & \dots & 0 \\ 0 & w^{(2)} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & w^{(n)} \end{bmatrix} \begin{bmatrix} u^{(1)} \\ u^{(2)} \\ \vdots \\ u^{(n)} \end{bmatrix} = \mathbf{W}\underline{\mathbf{u}} = \mathbf{W}(\mathbf{X}\underline{\theta} - \underline{\mathbf{y}}) \quad (9)$$

De esta forma, se tiene entonces que

$$\sum_{i=1}^n w^{(i)}(\underline{\theta}^T \underline{\mathbf{x}}^{(i)} - y^{(i)})^2 = \sum_{i=1}^n u_i w^{(i)} u_i = \underline{\mathbf{u}}^T \underline{\mathbf{v}} = (\mathbf{X}\underline{\theta} - \underline{\mathbf{y}})^T \mathbf{W}(\mathbf{X}\underline{\theta} - \underline{\mathbf{y}}) \quad (10)$$

II-B. Ejercicio 1.2

Sea la matriz de diseño $\mathbf{X} \in \mathbb{R}^{m \times n}$, el vector $\underline{\theta}$ de tamaño n , el vector $\underline{\mathbf{y}}$ de tamaño m , y la matrix diagonal $\mathbf{W} \in \mathbb{R}^{m \times m}$

Se define entonces $J(\underline{\theta}) = \frac{1}{2}(\mathbf{X}\underline{\theta} - \underline{\mathbf{y}})^T \mathbf{W}(\mathbf{X}\underline{\theta} - \underline{\mathbf{y}})$, y se debe de calcular $\nabla_{\underline{\theta}} J(\underline{\theta}) = 0$

Procedimiento:

$$J(\underline{\theta}) = \frac{1}{2}(\underline{\theta}^T \mathbf{X}^T - \underline{\mathbf{y}}^T)(\mathbf{W}\mathbf{X}\underline{\theta} - \mathbf{W}\underline{\mathbf{y}}) \quad (11)$$

$$J(\underline{\theta}) = \frac{1}{2}(\underline{\theta}^T \mathbf{X}^T \mathbf{W}\mathbf{X}\underline{\theta} - \underline{\mathbf{y}}^T \mathbf{W}\mathbf{X}\underline{\theta} - \underline{\theta}^T \mathbf{X}^T \mathbf{W}\underline{\mathbf{y}} + \underline{\mathbf{y}}^T \mathbf{W}\underline{\mathbf{y}}) \quad (12)$$

De esta manera se tiene que el gradiente es la suma de gradientes

$$\nabla_{\underline{\theta}} J(\underline{\theta}) = \frac{1}{2}(\nabla_{\underline{\theta}}(\underline{\theta}^T \mathbf{X}^T \mathbf{W}\mathbf{X}\underline{\theta}) - \nabla_{\underline{\theta}}(\underline{\mathbf{y}}^T \mathbf{W}\mathbf{X}\underline{\theta}) - \nabla_{\underline{\theta}}(\underline{\theta}^T \mathbf{X}^T \mathbf{W}\underline{\mathbf{y}}) + \nabla_{\underline{\theta}}(\underline{\mathbf{y}}^T \mathbf{W}\underline{\mathbf{y}})) \quad (13)$$

Para el primer término se usa (2) y (3), ya que el valor interno tiene tamaño $(1 \times n)(n \times m)(m \times m)(m \times n)(n \times 1) = (1 \times 1)$, o sea es un escalar. Y con $\mathbf{A} = \underline{\theta}^T$, $\mathbf{B} = \mathbf{X}^T \mathbf{W}\mathbf{X}$, $\mathbf{C} = \mathbf{I}$, se obtiene entonces

$$\nabla_{\underline{\theta}}(\underline{\theta}^T \mathbf{X}^T \mathbf{W}\mathbf{X}\underline{\theta}) = \nabla_{\underline{\theta}} \text{tr}(\underline{\theta}^T \mathbf{X}^T \mathbf{W}\mathbf{X}\underline{\theta}) = \mathbf{X}^T \mathbf{W}^T \mathbf{X}\underline{\theta} + \mathbf{X}^T \mathbf{W}\mathbf{X}\underline{\theta} \quad (14)$$

Para el segundo término, se utiliza la ecuación (4), junto a la (2) ya que el resultado es escalar

$$-\nabla_{\underline{\theta}}(\underline{\mathbf{y}}^T \mathbf{W}\mathbf{X}\underline{\theta}) = -\nabla_{\underline{\theta}} \text{tr}(\underline{\mathbf{y}}^T \mathbf{W}\mathbf{X}\underline{\theta}) = -\mathbf{X}^T \mathbf{W}\underline{\mathbf{y}} \quad (15)$$

Para el tercer término se usan las ecuaciones (4) y la (5), junto a la (2) ya que el resultado es escalar

$$-\nabla_{\underline{\theta}}(\underline{\theta}^T \mathbf{X}^T \mathbf{W}\underline{\mathbf{y}}) = -\nabla_{\underline{\theta}} \text{tr}(\underline{\theta}^T \mathbf{X}^T \mathbf{W}\underline{\mathbf{y}}) = -(\nabla_{\underline{\theta}} \text{tr}(\underline{\theta}^T \mathbf{X}^T \mathbf{W}\underline{\mathbf{y}}))^T = -(\underline{\mathbf{y}}^T \mathbf{W}^T \mathbf{X})^T = -\mathbf{X}^T \mathbf{W}^T \underline{\mathbf{y}} \quad (16)$$

El cuarto término no depende de $\underline{\theta}$, por lo tanto el gradiente es 0

De esta manera se obtiene que

$$\nabla_{\underline{\theta}} J(\underline{\theta}) = \frac{1}{2}(\mathbf{X}^T \mathbf{W}^T \mathbf{X}\underline{\theta} + \mathbf{X}^T \mathbf{W}\mathbf{X}\underline{\theta} - \mathbf{X}^T \mathbf{W}\underline{\mathbf{y}} - \mathbf{X}^T \mathbf{W}^T \underline{\mathbf{y}}) \quad (17)$$

Dado que \mathbf{W} es diagonal entonces $\mathbf{W}^T = \mathbf{W}$ y esa ecuación se convierte en

$$\nabla_{\underline{\theta}} J(\underline{\theta}) = \frac{1}{2}(2\mathbf{X}^T \mathbf{W}\mathbf{X}\underline{\theta} - 2\mathbf{X}^T \mathbf{W}\underline{\mathbf{y}}) = \mathbf{X}^T \mathbf{W}\mathbf{X}\underline{\theta} - \mathbf{X}^T \mathbf{W}\underline{\mathbf{y}} \quad (18)$$

A partir de esta ecuación se puede despejar para $\nabla_{\underline{\theta}} J(\underline{\theta}) = 0$

$$\underline{\theta} = (\mathbf{X}^T \mathbf{W}\mathbf{X})^{-1} \mathbf{X}^T \mathbf{W}\underline{\mathbf{y}} \quad (19)$$

II-C. Ejercicio 1.3

La verosimilitud se define como

$$L(\underline{\theta}) = p(\mathbf{Y}|\mathbf{X}; \underline{\theta}) \quad (20)$$

En donde contodos los m datos independientes se convierte en

$$L(\underline{\theta}) = p(\mathbf{Y}|\mathbf{X}; \underline{\theta}) = \prod_{i=1}^m p(y^{(i)}|x^{(i)}; \underline{\theta}) \quad (21)$$

Realizando la suposición que

$$p(y^{(i)}|x^{(i)}; \underline{\theta}) = \frac{1}{\sqrt{2\pi}\sigma^{(i)}} \exp\left(-\frac{(y^{(i)} - \underline{\theta}^T \mathbf{x})^2}{2(\sigma^{(i)})^2}\right) \quad (22)$$

Se obtiene

$$L(\underline{\theta}) = p(\mathbf{Y}|\mathbf{X}; \underline{\theta}) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma^{(i)}} \exp\left(-\frac{(y^{(i)} - \underline{\theta}^T \mathbf{x})^2}{2(\sigma^{(i)})^2}\right) \quad (23)$$

Debido a que se le debe encontrar el $\underline{\theta}^* = \arg \max_{\underline{\theta}} L(\underline{\theta})$

Esto es equivalente a encontrar $\underline{\theta}^* = \arg \max_{\underline{\theta}} \ln(L(\underline{\theta}))$, el log-likelihood, el cual tiene ecuación

$$\ell(\underline{\theta}) = \ln(L(\underline{\theta})) = \ln\left(\prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma^{(i)}} \exp\left(-\frac{(y^{(i)} - \underline{\theta}^T \mathbf{x})^2}{2(\sigma^{(i)})^2}\right)\right) = \sum_{i=1}^m \ln\left(\frac{1}{\sqrt{2\pi}\sigma^{(i)}} \exp\left(-\frac{(y^{(i)} - \underline{\theta}^T \mathbf{x})^2}{2(\sigma^{(i)})^2}\right)\right) \quad (24)$$

Desarrollando esta suma

$$\ell(\underline{\theta}) = \sum_{i=1}^m \ln\left(\frac{1}{\sqrt{2\pi}\sigma^{(i)}}\right) - \left(\frac{(y^{(i)} - \underline{\theta}^T \mathbf{x})^2}{2(\sigma^{(i)})^2}\right) \quad (25)$$

El primer término de la suma no afecta el máximo de $\ell(\underline{\theta})$, por lo tanto

$$\underline{\theta}^* = \arg \max_{\underline{\theta}} \left(\frac{-1}{2} \sum_{i=1}^m \frac{1}{(\sigma^{(i)})^2} (\underline{\theta}^T \mathbf{x} - y^{(i)})^2 \right) \quad (26)$$

De aquí se observa que esta ecuación es igual a la ponderada considerando que $w^{(i)} = \frac{1}{(\sigma^{(i)})^2}$, solamente para minimizar el error J, maximizando la verosimilitud.

III. GRÁFICAS GENERADAS

Aquí para la figura 2 se puede apreciar que conforme aumenta el valor de τ , la curva se va linealizando, ya que el término $w^{(i)} = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}^{(i)}\|^2}{2\tau^2}\right)$ tiende a 1 y por lo tanto la regresión se va convirtiendo en lineal.

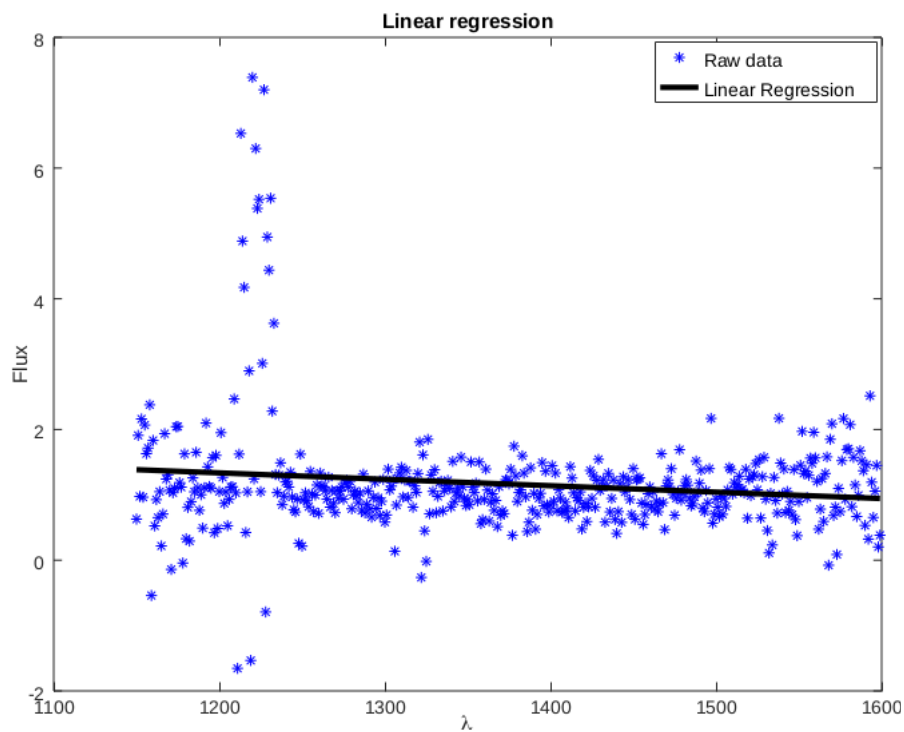


Figura 1: Regresión lineal

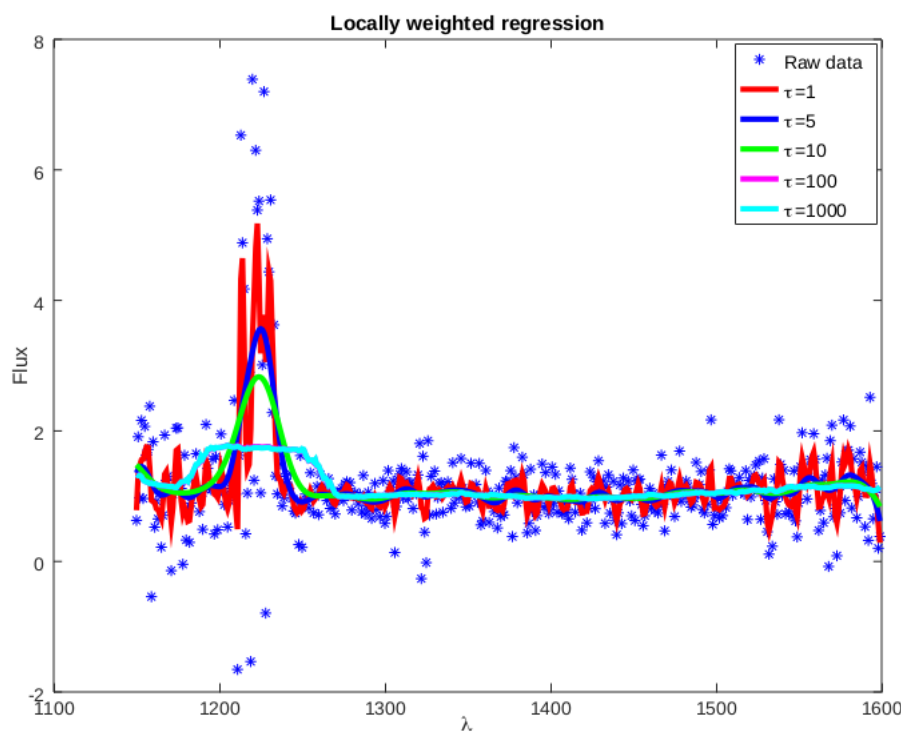


Figura 2: Regresión localmente ponderada